# **STA401**

# Statistique et Calcul des Probabilités

Responsable: Carole Durand-Desprez

14 Séances de Cours Amphi

13 Séances de TD

13 séances de TP

# Modalités d'examen

CC1: Tp (20%)

CC2: Td (20%)

Examen: Ecrit final (60%)



#### CHAPITRE 1 : Calcul de Probabilité et Statistique (révision + nouveautés).

- 1. Statistiques descriptives sur un échantillon.
- 2. Rappels de Probabilité (généralités et formules Proba conditionnelle Bayes)
- 3. Lois de probabilité discrètes (Uniforme, Bernoulli, Binomiale, Hypergéométrique, Poisson).
- 4. Inégalités de Markov et de Bienaymé Tchebychev.

#### CHAPITRE 2 : Lois continues ( "Autour" de la loi Normale)

- 1. Lois de probabilité continues (Généralités. Uniforme, Exponentielle ...).
- 2. Loi Normale (Gauss) Proriétés Lecture de table.
- 3. Théorème Central Limite. Théorème de Moivre-Laplace.
- **4.** Intervalles de fluctuation.
- 5. Quelques autres lois usuelles continues (liens avec la loi normale).



### **CHAPITRE 3 : Statistique décisionnelle - Estimation**

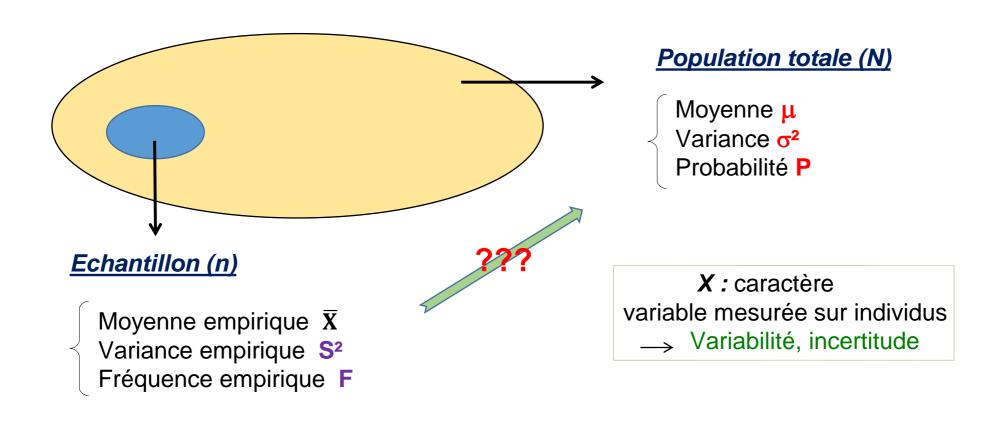
- **1.** Estimation ponctuelle ( estimateur, maximum de vraisemblance, lois des estimateurs)
- 2. Estimation par intervalles de confiance.

#### **CHAPITRE 4 : Tests Statistiques**

- 1. Généralités sur les tests. Notion de risques et d'hypothèses.
- 2. Tests de conformité (paramétriques) : moyenne, variance, probabilité.
- 3. La Pvaleur d'un test.
- **4.** La puissance d'un test.
- 5. Un test paramétrique particulier : le test de données appariées.
- 6. Tests de comparaison de 2 éch. indépendants (moyennes, variances, probabilités)
- 7. Tests du Khi-deux (ajustement et indépendance).

# **CHAPITRE 1 : Remise à niveau – Révision**

#### A quoi servent les statistiques ? Pour quoi faire ?



#### 1. Statistiques descriptives. Données sur un échantillon :

X variable numérique (quantitative). Données : valeurs sur un échantillon :  $x_1, x_2, \ldots, x_n$ 

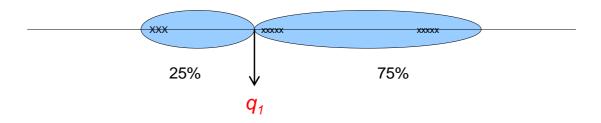
Moyenne empirique : 
$$\bar{x} = \frac{1}{n} \sum x_i$$

Varianceempirique: 
$$s^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i)^2 - (\bar{x})^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Ecart type empirique : s

Fréquence empirique :  $f = \frac{k}{n}$  (k nombre de réalisations d'un évènement A)

<u>La médiane</u>  $m_d$  est la plus petite valeur prise par X telle qu'au moins la moitié des effectifs soit inférieur. <u>Le premier quartile</u>  $q_1$  est la plus petite valeur prise par X telle qu'au moins le quart des effectifs soit inférieur. <u>Le troisième quartile</u>  $q_3$  est la plus petite valeur prise par X telle qu'au moins les  $\frac{3}{4}$  des effectifs soit inférieur.



Un échantillon est centré si sa moyenne est 0. Il est réduit si sa variance est 1

<u>Cas de données regroupées en classes</u>:  $C_1, ..., C_k$  de centres  $c_1, ..., c_k$ Soient  $n_1, ..., n_k$  les effectifs de chaque classe, et n la taille de l'échantillon


$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i = \frac{1}{n} \sum_{i=1}^{n} n_i c_i$$
  $s^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^{n} (n_i c_i - \bar{x})^2$ 

**Graphiques**:

Cas discret : diagramme en bâton

Cas continu : histogramme

**Fonction de répartition**:  $F(x) = P(X \le x)$ 

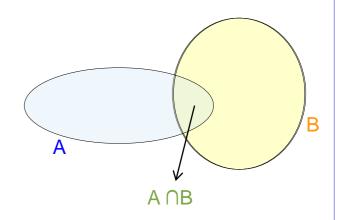


#### 2. Probabilités (généralités et formules - révisions)

Soit  $\Omega$  l'ensemble de toutes les éventualités d'une expérience. Soit E l'ensemble des évènements possibles. A un évènement et A son évènement complémentaire.

Une probabilité P est une application de E dans [0;1].

$$P(\Omega) = 1, \quad P(\emptyset) = 0, \quad 0 \le P(A) \le 1,$$
 $P(\bar{A}) = 1 - P(A)$ 
 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ 
 $P(A) = P(A \cap B) + P(A \cap \bar{B})$ 
 $P(A \mid B) = \frac{P(A \cap B)}{P(B)}$ 
 $P(A \mid B) = P(A \mid B)P(B) + P(A \mid \bar{B})P(\bar{B})$ 



#### A et B sont disjoints (incompatibles) si :

$$P(A \cap B) = 0$$
 (ou bien :  $A \cap B = \emptyset$ )

#### A et B sont indépendants si :

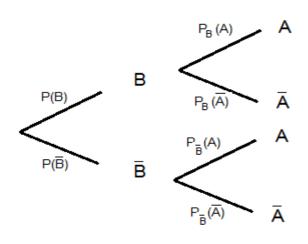
$$P(A \cap B) = P(A) * P(B)$$
 ou  $P(A \mid B) = P(A)$ 

Autre notation: 
$$P(A \mid B) = P_B(A)$$

#### Formule de Bayes :

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)} = \frac{P(B \mid A)P(A)}{P(B \mid A)P(A) + P(B \mid \bar{A})P(\bar{A})}$$

$$Cas\ g\'{e}n\'{e}ral\ (Si\ A=A_1\cup\ldots\cup A_n, et\ disjoints): \qquad P(A_1\mid B)=\frac{P(B\mid A_1)P(A_1)}{\sum_{i=1}^n P\left(B\mid A_i\right)P(A_i)}$$



| Var1 \ Var2 | Α                   | Ā                         | Total        |
|-------------|---------------------|---------------------------|--------------|
| В           | $P(A \cap B)$       | $P(\bar{A}\cap B)$        | P(B)         |
| B           | $P(A \cap \bar{B})$ | $P(\bar{A} \cap \bar{B})$ | $P(\bar{B})$ |
| Total       | P(A)                | $P(\bar{A})$              | 1            |

#### Arbre pondéré

#### Tableau croisé



Sur le graphique ...

$$P(A \cap B) = P(B) * P(A \mid B)$$



Dans le tableau ...

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

#### 3. Lois de probabilités usuelles discrètes :

 $\longrightarrow$  Une variable variable X est une application sur  $\Omega$ .

**Exemple**: On lance un dé (expérience).  $\Omega = \{f_1, ..., f_6\}$ .

Evènement A: "tomber sur un nombre pair"; B: "tomber sur un nombre inférieur à 5"

X la variable :  $X(f_i)$  = 'gain de i euros' ... Les valeurs possibles de X :  $\{1,2,3,4,5,6\}$ 

Y variable : Y(f<sub>i</sub>) = 'gain de i € si i pair, sinon 0' ... Les valeurs possibles de Y : {0,2,4,6}

 $\rightarrow$  Loi de probabilité P d'une variable X discrète (finie), valeurs possibles  $\{x_1, ..., x_n\}$ :

$$P(X = x_i) = p_i \quad \forall i, \qquad \sum_{i=1}^{n} p_i = 1$$

$$E[X] = \mu = \sum_{i=1}^{n} x_i p_i$$

$$V[X] = \sigma^2 = E[X - E[X]]^2$$

$$= \sum_{i=1}^{n} (x_i - \mu)^2 p_i = \sum_{i=1}^{n} (x_i)^2 p_i - \mu^2$$

---> Espérance

----> Variance

$$\longrightarrow Propriété: E[aX + bY] = aE[X] + bE[Y]$$

Linéarité de l'espérance évidente.

Propriétés: 
$$V[X] = E[X - E[X]]^2 = E[X^2] - (E[X])^2$$
$$V[aX + b] = a^2V[X]$$

$$\longrightarrow$$
 Loi uniforme (équiprobable) :  $\forall i$ ,  $p_i = 1/n$ 

Exemple: Un dé non pipé, 
$$\Omega = \{1, ..., 6\}$$
, variable  $X(i) = i$ ,  $P(X=i) = p_i = 1/6$   
 $E[X] = 1*1/6 + 2*1/6 + ... + 6*1/6 = 3,5$   $V[X] = (1^2 + ... + 6^2)/6 - 3,5^2 = 2,916...$ 

-> Loi Bernoulli (p): A un évènement qui se réalise avec une probabilité p.

$$X = \begin{cases} 1 & \text{si A se r\'ealise avec proba } (p) \\ 0 & \text{si A non r\'ealis\'e proba } (1-p) \end{cases}$$
 X suit la loi Bernoulli (p)

$$P(X = 1) = p \ et \ P(X = 0) = 1 - p \ ; \ E[X] = p \ ; \ V[X] = p(1 - p)$$

Loi Binomiale (n,p): A est un évènement qui se réalise avec une probabilité p. On refait n expériences indépendantes. X<sub>i</sub> variables de Bernoulli (p) <u>indépendantes</u>

$$X = \sum_{i} X_{i}$$
 est le nombre de réalisations de A parmi les n possibles.

X suit la loi Binomiale (n,p) Valeurs possibles de X : {0,1, ..., n}

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n - k} \; ; \; E[X] = np \; ; \; V[X] = np(1 - p)$$

#### Rappel: Combinatoire

On prend simultanément k objets parmi un ensemble en contenant n  $(n \ge k)$ .

Le nombre de combinaisons possibles est :  $\binom{n}{k} = \frac{n!}{(n-k)! \ k!}$  autre notation :  $C_n^k$ 

**Exemple**: A: "être un étudiant de la filière INF dans l'amphi", probabilité p=90%. Dans un amphi N=60, on prend n=10 individus (tirages indépendants, avec remise). X : nombre d'étudiants du groupe INF parmi les n=10

## Indépendance (avec remise) X suit B(10; 0,9)



 $P(X=0)=(0,1)^{10}=10^{-10}$  ... voir calculatrice aussi ...

$$E(X) = 10*0.9 = 9$$

V(X) = 10\*0.9\*0.1 = 0.9

#### → Loi Hypergéométrique (N,m,n):

Soit une population de N individus dont m individus réalisent un évènement A. On prend un échantillon de n individus (sans remise).

y est le nombre d'individus qui réalisent A parmi les n possibles.

X suit la loi Hypergéométrique (N,m,n) Valeurs possibles de X : {0,1, ..., min(n;m)}

$$P(X = k) = \frac{\binom{m}{k} \binom{N - m}{n - k}}{\binom{N}{n}} \quad ; \quad E[X] = \frac{nm}{N} \quad ; \quad V[X] = n\left(\frac{m}{N}\right) \left(\frac{N - m}{N}\right) \left(\frac{N - m}{N}\right)$$

**Exemple**: Population: "amphi de sta401" avec N=60 étudiants, A: "être un étudiant de la filière INF", m=50 étudiants sont des INF.

On prend un échantillon de n=8 individus (tirages sans remise).

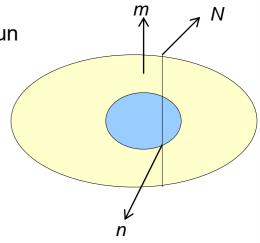
X : nombre d'étudiants du groupe INF parmi les n=8

Indépendance (sans remise) 

X suit H(60;50;8)

 $P(X=0) = 1*45 / 2558620845 = 1,7588.10^{-8} \dots$  voir calculatrice aussi ...

E(X) = 8\*50/60 = 6,66666...



#### $\rightarrow$ Loi de Poisson ( $\lambda$ ):

Soit un évènement A qui arrive 'rarement' dans le temps.

On observe pendant un certain laps de temps cet évènement.

X est le nombre d'évènements qui se réalisent.

X suit la loi de Poisson ( $\lambda$ ) Valeurs possibles de X : {0,1, ...}

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \; ; \quad E(X) = \lambda \; ; \quad V(X) = \lambda$$

**Exemple**: En sta401, on a constaté qu'en moyenne 2 étudiants posaient une question pendant l'examen.

X : nombre d'étudiants qui posent des questions cette année  $\implies$  X suit P(2)  $P(X=4) = 2^4 e^{-2} / 4! = 0,0902...$ 

#### Propriété 1 :

Soient X suit  $P(\lambda_1)$  et Y suit  $P(\lambda_2)$  indépendantes, alors : X+Y suit  $P(\lambda_1+\lambda_2)$ 

#### Propriété 2 : Approximation d'une loi Binomiale par une loi de Poisson

Lorsque n est grand (n>50) et p est petit (p<0,1) alors :  $B(n;p) \approx P(\lambda)$  avec  $\lambda = np$ 

<u>Dém</u>: Voir les 2 démonstrations en TD à titre d'exercices.

#### 4. Inégalités à connaître (également applicables au cas continu du chapitre suivant) :

#### + Inégalité de Markov

Soit X v.a. positive, pour tout a > 0:  $P(X \ge a) \le \frac{E(X)}{a}$ 

$$P(X \ge a) \le \frac{E(X)}{a}$$

<u>Dém</u>: Soient  $(x_i)_i$  les valeurs possibles prises par X, alors :

$$E(X) = \sum_{x_i} P(X = x_i) x_i = \sum_{x_i < a} P(X = x_i) x_i + \sum_{x_i \ge a} P(X = x_i) x_i \ge 0 + \sum_{x_i \ge a} P(X = x_i) x_i$$

$$\ge a \sum_{x_i \ge a} P(X = x_i) \ge a P(X \ge a) . \quad Donc, \qquad P(X \ge a) \le \frac{E(X)}{a}$$

#### Inégalité de Bienaymé Tchebychev

Soit X v.a. positive, pour tout 
$$a > 0$$
:  $P(|X - E(X)| \ge a) \le \frac{V(X)}{a^2}$ 

<u>Dém</u>: Dans l'inégalité de Markov on remplace a par  $a^2$  et X par  $(X - E(X))^2$ :

Donc, 
$$P\left(\left(X - E(X)\right)^2 \ge a^2\right) \le \frac{E\left(X - E(X)\right)^2}{a^2}$$
. On déduit aisément :  $P(|X - E(X)| \ge a) \le \frac{V(X)}{a^2}$ 

<u>Application</u>: Trouver le plus petit h tel que (interv. centré sur moyenne):  $P[E(X) - h \le X \le E(X) + h] \ge 0.95$ 

$$\longrightarrow P[|X - E(X)| \le h] \ge 0.95 \Rightarrow P[|X - E(X)| \ge h] \le 0.05 \quad IBT : h = \sqrt{V(X)/0.05}$$